

국가별 무역구조 기반 Clustering 분석 보고서

K-Means → DBSCAN → RF/SVM → Bootstrap ARI → 군집별 심층분석

데이터 출처: UN Comtrade 무역통계, World Bank 거시경제지표 (2023)

분석 대상: 161개국 × 18개 변수

산업경영공학부 2022170803 남윤성

목차

1. 분석 개요

1.1 분석 목적

1.2 분석 파이프라인

1.3 데이터 출처 및 품질 보정

1.4 사용 변수 정의

1.5 분석 도구

2. 데이터 전처리 및 피처 엔지니어링

2.1 무역 변수 구성

2.2 HS 96개 챕터 → 13개 경제 카테고리 통합

2.3 최종 Clustering 입력 변수

2.4 변수 간 상관관계 검토

2.5 무역개방도 분포 및 이상치 절단

2.6 결측치 처리

2.7 데이터 병합

3. K-Means Clustering

3.1 최적 군집 수(k) 결정

3.2 최종 군집 결과 및 실루엣 분석

3.3 군집별 중심값 해석

3.4 PCA 2차원 투영 시각화

3.5 군집별 수출 품목 구성

4. DBSCAN: 밀도 기반 이상국 탐지

4.1 분석 배경

4.2 파라미터 선정

4.3 민감도 분석

4.4 탐지된 이상국 및 해석

5. RF/SVM: 군집 분리 일관성 확인

5.1 분석 방법 및 한계

5.2 교차검증 정확도

5.3 혼동행렬 분석

5.4 변수 중요도

5.5 경계 국가 식별

6. 부트스트랩 ARI: 구조 안정성의 독립 검증

6.1 분석 배경 및 방법

6.2 결과 및 해석

7. 군집별 심층 분석

7.1 군집 안정성 종합 비교

7.2 특정 경계 국가 중심의 벤치마킹 갭(Gap) 분석

7.3 군집별 GDP 성장률 비교

7.4 변수 중요도 가설 대조

7.5 군집 간 보완적 무역구조 분석

8. 결론 및 시사점

8.1 주요 결론

8.2 분석의 한계

8.3 후속 연구 제안

9. 참고문헌

1. 분석 개요

1.1 분석 목적

본 연구는 2023년 UN Comtrade 무역통계와 World Bank 거시경제지표를 api를 통해 추출 후, 두 데이터를 결합하여 세계 각국을 무역구조의 유사성에 따라 군집화하고, 그 유형 분류의 안정성을 머신러닝을 통해 교차 검증하는 것을 주 목적으로 삼는다. 단순히 GDP나 소득수준으로 국가를 분류하는 기존 접근방식과는 다르게, 실제 수출입 품목 구성에 따른 무역 규모와 무역구조 관점에서 국가군을 재구성하여 각 유형이 가진 경제적 함의를 도출한다.

이를 위해 K-Means clustering 을 메인 분석으로 사용하고, DBSCAN을 통한 이상국 탐지, RF/SVM을 통한 분리 일관성 확인, 그리고 부트스트랩 ARI를 통한 독립적 구조 안정성 검증을 거치고, 마지막으로 군집별 심층분석까지 진행하는 5단계 파이프라인을 구성하여 체계적인 분석을 진행하고자 한다.

1.2 분석 파이프라인

본 분석은 다음의 5단계 파이프라인으로 구성된다.

- ① K-Means: 18개 구조변수를 활용해 국가를 5개 무역구조 유형으로 군집화하고, 군집 중심값을 해석한다.
- ② DBSCAN: 밀도 기반 Clustering으로 평균적 패턴에서 벗어난 이상국(outlier)을 식별한다.
- ③ RF/SVM: K-Means 군집 레이블의 복원 가능성을 교차검증하여 군집 경계의 일관성을 평가하고, 경계에 위치한 국가를 식별한다.
- ④ 부트스트랩 ARI: 80% 서브샘플에서 K-Means를 100회 반복하여 군집 구조의 안정성을 데이터 부분집합에서 독립적으로 검증한다.

⑤ 군집별 심층분석: 각 유형의 대표 국가, 통계적 프로파일, 경제적 시사점을 종합한다.

1.3 데이터 출처 및 품질 보정

① UN Comtrade 무역데이터

164개국의 HS 챕터(2자리 코드, 1~97) 단위 수출(X)·수입(M) 거래액을 포함한다. 원본 CSV는 헤더(47개 필드)와 실제 데이터 행(48개 필드) 간 불일치가 있어, 47개 필드만 사용하도록 전처리하여 해결하였다. 거래액은 수입 CIF, 수출 FOB 기준이 혼재되어 있어, UN Comtrade가 제공하는 통합 거래가치 필드(primaryValue)를 일관되게 사용하였다.

② World Bank 거시경제지표

GDP, 인구, GDP성장률, 인플레이션, 제조업 부가가치 비중(Mfg_VA_GDP), 자원렌트 비중(Res_Rent_GDP), 무역수지/GDP 비율을 포함한 2023년 기준 데이터이다.

데이터 품질 이슈 및 보정

World Bank API는 기본 per_page=50 설정으로 인해 국가명 알파벳 U~Z에 해당하는 다수 국가(미국, 영국, 베트남, 우크라이나, 아랍에미리트, 우즈베키스탄 등)가 통째로 누락되는 페이지네이션 문제가 있었다. 이를 per_page=500으로 보정하여 전체 국가를 수신하였다.

또한 자원렌트 비중(NY.GDP.TOTL.RT.ZS) 지표는 2023년 데이터가 미발행 상태였으므로, date=2019:2023 범위에서 각 국가의 가장 최근 유효값을 자동 선택하는 방식으로 보정하였다. 이 결과 분석 대상이 기존 150개국에서 161개국으로 확대되었으며, 미국(GDP 27.3조 달러), 영국(3.4조), 베트남(4,340억), UAE(5,230억) 등 주요 교역국이 분석에 포함되었다.

1.4 사용 변수 정의

본 분석에서 사용한 원본 변수의 출처와 정의는 다음과 같다. UN Comtrade 변수는 무역 피처

가공의 입력값이며, World Bank 변수는 거시경제지표로 직접 사용되거나 일부는 파생변수 계산에 사용된다.

UN Comtrade 무역데이터 (원본 47개 필드 중 분석에 사용된 핵심 변수)

변수명	설명
reporterISO	보고국 ISO3 코드 (예: KOR, USA)
reporterDesc	보고국 국가명
flowCode	무역방향 (X=수출, M=수입)
cmdCode	HS 챕터 코드 (2자리, 01~97)
cmdDesc	HS 챕터 품목 설명 (예: '01'→'Animals; live')
primaryValue	거래액 (USD, 수출입 통합 기준값)

World Bank 거시경제지표 (8개 원본 변수)

변수명	World Bank 지표코드	설명	본 분석에서의 역할
iso3	-	국가 ISO3 코드	병합 키(key)
country_name	-	국가명	결과 해석용 라벨
gdp_usd	NY.GDP.MKTP.CD	GDP (현재가, USD)	무역개방도 계산의 분모
population	SP.POP.TOTL	총인구	참고용 (직접 미사용)
GDP_Growth	NY.GDP.MKTP.KD.ZG	실질 GDP 성장률 (연간 %)	7.3절 군집별 성장률 비교에 사용
Inflation	FP.CPI.TOTL.ZG	소비자물가 인플레이션 (연간 %)	참고용 (직접 미사용)
Mfg_VA_GDP	NV.IND.MANF.ZS	제조업 부가가치 / GDP (%)	clustering 입력변수
Res_Rent_GDP	NY.GDP.TOTL.RT.ZS	자원렌트 / GDP (%)	clustering 입력변수
Trade_Balance_GDP	NE.RSB.GNFS.ZS	무역수지 / GDP (%)	clustering 입력변수

이 중 population과 Inflation은 World Bank 원본 데이터셋에는 포함되어 있으나 본 분석의 18개 clustering 변수에는 직접 사용되지 않았으며, GDP_Growth는 clustering 입력이 아니라 7.3절에서 군집 결과를 사후적으로 해석하는 외부 검증 변수로 사용되었다.

1.5 분석 도구

Python 3.12, pandas, scikit-learn(KMeans, DBSCAN, RandomForestClassifier, SVC),

matplotlib/seaborn을 사용하였다. 전체 분석 코드는 별첨 Jupyter

Notebook(trade_clustering_analysis.ipynb)에 단계별로 정리되어 있으며, 본 보고서의 모든 수치와 그림은 해당 노트북의 실행 결과와 일치한다.

2. 데이터 전처리 및 피처 엔지니어링


2.1 무역 변수 구성: 수출입 통합 및 비중화

국가(reporterISO) × 품목(HS 챕터, 1~97) × 무역방향(수출/수입) 단위로 거래액을 집계한 뒤, 다음 절차로 clustering 변수를 구성하였다.

먼저, 국가별 총수출액과 총수입액을 산출하고, 무역수지(수출-수입)를 계산하였다. 다음으로, 국가별 수출 포트폴리오 비중(품목별 수출액 / 총수출액)을 계산하여 국가 규모와 무관하게 '무엇을 수출하는가'라는 구조적 특성을 포착하였다. 마지막으로, 수출 집중도 지수(HHI, Herfindahl-Hirschman Index)를 수출비중의 제곱합으로 산출하였다. HHI 값이 높을수록 소수 품목에 수출이 집중됨을 의미한다.

2.2 HS 96 개 챕터 → 13 개 경제 카테고리 통합

96개 HS 챕터 수출비중을 그대로 clustering 변수로 사용할 경우, 변수 수가 과다하여 차원의 저주(curse of dimensionality) 문제가 발생할 수 있다. 실제로 PCA를 적용한 결과 20개 주성분으로도 누적 설명분산이 55%에 불과하여 저차원 구조가 뚜렷하지 않았다(그림 1 참조). 이에 HS 챕터를 경제적으로 해석 가능한 상위 카테고리로 통합하여 변수 수를 줄이되, 무역구조의 핵심적 차이를 보존하는 방향으로 피처를 설계하였다.



[그림 1] 96개 HS 챕터 수출비중에 대한 PCA 누적설명분산 — 20개 주성분으로도 55%에 불과

통합 기준은 세계관세기구(WCO)가 정의한 HS 공식 Section 체계(I~XXI, 총 21개)를 기반으로 하되, 경제적 유사성이 높고 개별 비중이 작은 인접 섹션을 통합하여 최종 13개 카테고리를 구성하였다. 구체적인 대응 관계는 다음과 같다.

카테고리	WCO Section	HS	통합 근거
Agri_Food	I + II + III + IV	1~24	농축수산물·유지류·가공식품을 1차산업 및 식품가공으로 일괄 통합. 무역구조상 식량 수출국 특성을 단일 변수로 포착
Mineral_Fuel	V	25~27	광물·연료 자원은 자원수출 의존형 국가의 핵심 지표
Chemicals	VI	28~38	화학제품은 중화학공업 발전 단계를 반영하는 독립 범주
Plastics_Rubber	VII	39~40	석유화학 파생 산업으로 독립적 경제적 의미 보유
Hides_Leather	VIII	41~43	가죽·모피 산업은 특정 개도국 수출 특화 품목
Wood_Paper	IX + X	44~49	목재(IX)·제지(X)를 임산 자원 기반 산업으로 통합
Textiles_Apparel	XI	50~63	섬유·의류는 노동집약적 제조업의 대표 지표
Footwear_Misc_Light	XII	64~67	신발·모자·우산 등 경공업 제품
Stone_Glass_Precious	XIII + XIV	68~71	석재·유리·세라믹(XIII)과 귀금속·보석(XIV)은 모두 비금속 광물 가공 산업으로, 금·다이아몬드 수출국의 특성을 함께 포착하기 위해 통합

Base_Metals	XV	72~83	철강·비철금속 및 그 제품으로 중공업 기반 반영
Machinery_Electronics_Transport	XVI + XVII + XVIII	84~92	기계·전기장비(XVI), 운송장비(XVII), 정밀기기(XVIII)를 고부가가치 제조업 경쟁력 지표로 통합
Arms	XIX	93	특수 품목으로 독립 분류
Misc_Manufactured	XX + XXI	94~97	가구·완구·예술품 등 기타 잡제품을 일괄 통합


이에 따라 96개 HS 챗터를 경제적으로 해석 가능한 13개 카테고리(농식품, 광물연료, 화학, 플라스틱/고무, 가죽, 목재/제지, 섬유/의류, 신발/경공업, 귀금속/보석, 기초금속, 기계/전자/운송, 무기, 기타제조)로 통합하였다. 이는 가공무역 중심형, 자원수출 의존형 등 구조적 유형 가설과 직접 대응되도록 설계한 것이다. 위 13개 카테고리 중 8개(Mineral_Fuel, Chemicals, Plastics_Rubber, Hides_Leather, Textiles_Apparel, Footwear_Misc_Light, Base_Metals, Arms)는 WCO 체계와 1:1로 대응되는 걸 볼 수 있다. 나머지 5개 카테고리(Agri_Food, Wood_Paper, Stone_Glass_Precious, Machinery_Electronics_Transport, Misc_Manufactured)는 경제적 유사성이 높은 인접 Section을 추가로 통합한 결과이다. 이러한 통합의 타당성은 최종 Clustering 결과에서도 확인할 수 있다. 13개 카테고리 변수로 도출된 5개 군집이 각각 경제학적으로 명확히 해석 가능한 유형(자원수출 의존형, 제조업/가공무역형 등)을 보여주며, Random Forest 변수 중 위의 통합 변수가 상위 중요도에 위치하여 카테고리 설계가 군집 분리에 실질적으로 기여하고 있음을 확인하였다.

2.3 최종 Clustering 입력 변수 (18 개)

구분	변수명	설명
거시구조	Mfg_VA_GDP	제조업 부가가치 / GDP (%)
거시구조	Res_Rent_GDP	자원렌트 / GDP (%)
거시구조	Trade_Balance_GDP	무역수지 / GDP (%)
무역구조	HHI_export	수출 품목 집중도 지수
무역구조	Trade_Openness_GDP	(수출+수입)/GDP (%), 상위 1% 절단
수출비중	EXPCAT_* (13개)	13개 경제 카테고리별 수출비중 (합계 1.0)

거시구조 5개 변수와 수출비중 13개 변수를 합쳐 총 18개 변수를 StandardScaler로 표준화한 뒤 clustering에 사용하였다. 추가 PCA 차원축소는 적용하지 않았다.

2.4 변수 간 상관관계 검토



[그림 2] 최종 18개 clustering 변수의 상관행렬


당초 가설은 제조업 부가가치 비중과 자원렌트 비중 사이에 강한 음의 상관관계가 있을 것으로 예상하였으나, 실제 상관계수는 -0.12로 약하게 나타났다. 이는 일부 국가가 제조업과 자원수출을 동시에 영위하는 복합형 경제구조를 가지고 있음을 시사하는 경험적 발견이다. 반면 광물연료 수출비중과 자원렌트 비중 간에는 0.68의 강한 양의 상관관계가 확인되어, 변수 구성의 타당성이 검증되었다. 전반적으로 다중공선성이 우려될 수준의 상관은 발견되지 않았다.

2.5 무역개방도 분포 및 이상치 절단

무역개방도($\text{Trade_Openness_GDP} = (\text{수출} + \text{수입}) / \text{GDP}$)는 평균 67.7%, 표준편차 42.7%로 우편향(right-skewed) 분포를 보인다(그림 3 좌측). 대부분의 국가가 40~85% 구간에 분포하는 반면,

홍콩(322%), 지부티(258%), UAE(181%), 슬로베니아(175%) 등 중계무역·환적(transshipment) 허브 국가들이 극단적으로 높은 값을 형성한다. 이들 국가는 자국 소비를 위한 무역이 아니라 재수출·환적 비중이 높아, GDP 대비 무역액이 실제 경제 규모에 비해 과대 계상되는 통계적 특성을 가진다.

이러한 극단값을 그대로 표준화(StandardScaler)에 투입할 경우 평균과 분산이 왜곡되어 다른 국가들의 상대적 위치가 압축되고, 결과적으로 Clustering이 소수 극단국에 과도하게 민감해질 수 있다. 이에 상위 1%(99th percentile, 약 211.6%)를 초과하는 값을 해당 임계값으로 절단(capping)하였다. 절단 대상은 홍콩과 지부티 2개국으로, 이들의 무역구조 자체를 분석에서 제외하지 않으면서도 극단값이 척도에 미치는 영향만 완화하였다. 그림 3 우측의 절단 전후 박스플롯에서 보듯, 절단 후에도 중앙값과 사분위 범위(IQR)는 거의 변하지 않아 일반 국가들의 분포는 보존되었다.



[그림 3] 무역개방도 분포 및 99% 절단 효과 — (좌) 절단 전 분포 히스토그램, (우) 절단 전후 박스플롯 비교

2.6 결측치 처리

World Bank 데이터 보정 후에도 일부 국가에서 거시지표 결측이 발생하였다. 구체적으로 Mfg_VA_GDP 3개국, Trade_Balance_GDP 21개국에 대해 중앙값(median) 대치를 적용하였다. Res_Rent_GDP는 2019~2023 범위 최신값 사용으로 결측 0건이다. 중앙값 대치된 국가가 인위

적으로 중앙 군집에 끌려가는 문제를 방지하기 위해, 최종 결과에서 해당 국가들의 군집 배정이 경제적 직관과 부합하는지 확인하였다.

2.7 데이터 병합

본 분석은 UN Comtrade 무역데이터와 World Bank 거시경제지표를 국가 ISO3 코드를 기준으로 내부 결합(inner join)하여 최종 분석 데이터셋을 구성하였다. 병합 과정에서의 국가 수 변동은 다음과 같다.

단계	국가 수	설명
UN Comtrade 무역데이터	164개국	HS 챕터 1~97 기준, 수출 또는 수입 기록이 1건 이상 존재하는 국가
World Bank 거시경제지표	247개 항목	국가 및 지역 집계(World, Upper middle income 등) 포함
Inner Join 결과 (최종 데이터)	161개국	양쪽 데이터 모두 존재하는 국가

병합 과정에서 탈락한 3개국은 다음과 같다. 몬세라트(MSR)는 영국 해외영토로 World Bank에 GDP 데이터가 존재하지 않으며, 예멘(YEM)은 내전으로 인해 2023년 GDP가 미보고 상태이다. S19는 UN Comtrade 내부의 기타 지역 집계 코드로 실제 국가가 아니다. 이들 3개국의 탈락이 전체 분석 결과에 미치는 영향은 무시할 수 있는 수준이라 판단하였다.


반대로 World Bank에는 존재하지만 UN Comtrade에 무역기록이 없는 86개 항목은 대부분 소규모 도서국(투발루, 나우루 등), 지역 집계 코드(East Asia & Pacific, Low income 등), 또는 UN에 무역통계를 보고하지 않는 국가이다.

병합 결과 161개국 × 18개 변수의 최종 분석 데이터셋이 구성되었으며, 이는 2023년 전 세계 상품 무역액의 약 98% 이상을 포괄하는 것으로 추정된다.

3. K-Means Clustering

3.1 최적 군집 수(k) 결정

Elbow(관성), Silhouette Score, Davies-Bouldin Index 세 가지 지표를 k=2~10 범위에서 비교하였다.




[그림 4] k값에 따른 Elbow / Silhouette / Davies-Bouldin 지표 변화

k=9, k=10 구간에서 실루엣 점수가 상승하지만, 실제 군집 크기를 확인한 결과 1~2개국으로만 구성된 극소 군집이 발생함을 확인하였다. 이는 일반적 구조가 아니라 이상치가 개별적으로 분리되는 현상으로 판단된다. k=5~7 구간은 군집 크기가 10~58개국으로 합리적으로 분포하며 실루엣 점수도 0.158~0.183 범위의 안정적 수준을 보인다. 해석 가능성과 표본 크기(161개국)를 종합적으로 고려하여 최종적으로 k=5를 선택하였다.

3.2 최종 군집 결과 및 실루엣 분석

k=5로 최종 학습한 K-Means의 평균 실루엣 점수는 0.158이다. 절대적 수치는 높지 않으나, 이는 국가 간 무역구조가 5개의 명확히 분리된 군집이 아니라 연속적인 스펙트럼 위에 존재한다는 경제적 현실을 반영한 것으로 해석할 수 있다. 이 해석은 이후 DBSCAN 분석에서도 일관되게 지지된다.



[그림 5] K-Means(k=5) 군집별 실루엣 플롯 (평균=0.158)

3.3 군집별 중심값(centroid) 해석

군집	명칭	n	제조업VA	자원렌트	HHI	무역수지	개방도	핵심수출
C0	섬유의류 특화형	10	14.0%	2.0%	0.12	-	58%	섬유의류 35.5%
C1	농식품 수출형	58	9.2%	3.5%	0.18	-6.1%	48%	농식품 39.8%
C2	귀금속/원자재 집중형	18	11.8%	9.9%	0.35	-	56%	귀금속 50.4%
C3	제조업/가공무역형	51	15.1%	1.0%	0.11	+	89%	기계전자 39.2%
C4	자원수출 의존형	24	7.8%	23.8%	0.53	+	75%	연료 69.6%

군집 C0: 섬유의류 특화형 (10개국, 6.2%)

섬유·의류 수출비중이 35.5%로 압도적이다. 파키스탄, 캄보디아, 미얀마, 스리랑카, 엘살바도르, 알바니아 등이 포함된다. 제조업 부가가치 비중은 14.0%로 상대적으로 높으나, 이는 섬유·의류 제조에 의한 것으로 기계·전자 등 고부가가치 제조와는 성격이 다르다. 노동집약적 경공업에 특화된 후발 산업화 국가군으로 해석할 수 있다.

군집 C1: 농식품 수출형 (58개국, 36.0%)

농식품 수출비중이 39.8%로 5개 군집 중 가장 높고, 무역적자 경향을 보인다. 캐나다, 인도, 브라질, 인도네시아, 남아프리카공화국, 칠레 등이 대표적이다. 평균 GDP 편차가 매우 커서(캐나다 2.1조 vs 소규모 농업국) 군집 내부의 다양성이 상당히 큰 편이다. 우크라이나, 우루과이 등 새로 추가된 국가들도 이 군집에 배정되어 경제적 직관과 부합한다.

군집 C2: 귀금속/원자재 집중형 (18개국, 11.2%)

보석·귀금속(주로 금, 다이아몬드 등) 수출비중이 50.4%로 단일 품목 의존도가 가장 높다. 수출 HHI(0.35)도 높은 편이다. 우즈베키스탄, 가나, 볼리비아, 아르메니아, 탄자니아, 짐바브웨 등 주로 아프리카·중앙아시아 내륙국이 다수 포함된다. 단일 1차산품 수출에 의존하는 전형적인 자원 기반 소규모 개방경제 유형이다.

군집 C3: 제조업/가공무역형 (51개국, 31.7%)


제조업 부가가치 비중(15.1%), 기계·전자·운송장비 수출비중(39.2%), 무역개방도(89%)가 모두 5개 군집 중 최고 수준이다. 중국, 미국, 독일, 네덜란드, 이탈리아, 일본, 한국, 영국, 베트남이 포함된다. 글로벌 가치사슬(GVC)에 깊이 편입되어 원자재를 수입해 고부가가치 제품으로 가공·수출하는 전형적인 가공무역 중심형 경제구조를 보여준다. 새로 추가된 미국·영국·베트남이 모두 이 군집에 배정되어 데이터 보정의 타당성을 확인할 수 있다.

군집 C4: 자원수출 의존형 (24개국, 14.9%)

자원렌트 비중(23.8%), 광물연료 수출비중(69.6%), 수출 HHI(0.53)가 모두 5개 군집 중 최고 수준이며, 무역수지는 흑자이다. UAE, 호주, 사우디아라비아, 노르웨이, 카타르, 쿠웨이트가 대표적이다. 호주·노르웨이와 같은 선진 자원수출국과 나이지리아·카자흐스탄과 같은 신흥 자원수출국이 함께 묶여 있다는 점에서, 본 군집은 자원 의존도라는 공통된 무역구조적 특성이 소득수준

의 차이를 초월하는 더 강력한 분류 기준임을 보여준다. 새로 추가된 UAE가 이 군집에 배정된 것은 경제적 직관과 완벽히 부합한다.


3.4 PCA 2 차원 투영을 통한 군집 시각화



[그림 6] K-Means 군집 결과의 PCA 2D 투영 (PC1+PC2 누적 설명분산 31.3%)

2차원 투영에서도 자원수출 의존형과 제조업/가공무역형이 시각적으로 뚜렷이 분리되는 경향이 확인된다. 한국(KOR), 중국(CHN), 독일(DEU), 미국(USA), 일본(JPN)이 제조업/가공무역형 군집 내에 위치하며, 사우디(SAU), 나이지리아(NGA)가 자원수출 의존형에 위치하는 것은 실제 경제구조와 부합하는 직관적인 결과다.

3.5 군집별 수출 품목 구성



[그림 7] 군집별 평균 수출 카테고리 비중

각 군집의 수출 구성이 명확히 차별화됨을 시각적으로 확인할 수 있다. 자원수출 의존형은 연료가 압도적이고, 제조업/가공무역형은 기계·전자가 지배적이며, 농식품 수출형은 농식품이 가장 큰 비중을 차지한다.


4. DBSCAN: 밀도 기반 이상국 탐지

4.1 분석 배경

K-Means는 모든 국가를 강제로 5개 군집 중 하나에 배정하는 분할(partitioning) 방식이므로, 평균적 패턴에서 크게 벗어난 이상국(outlier)이 가장 가까운 군집에 인위적으로 흡수되는 한계가 있다. 이를 보완하기 위해 밀도 기반 Clustering 기법인 DBSCAN을 적용하여, 주변 국가와의 밀도가 낮은 지점에 위치한 국가를 통계적 이상치로 별도 식별하였다.

4.2 파라미터(eps) 선정: k-거리 그래프

min_samples=5로 고정한 k-거리 그래프를 이용하여 eps의 적정 구간을 탐색하였다.



[그림 8] DBSCAN eps 선정을 위한 5-거리 그래프

그래프에서 약 140~150번째 국가 지점에서 명확한 변곡점(elbow)이 관찰되며, 이때 k-거리 값은 약 4.0~4.3이다.


4.3 민감도 분석

이 구간을 중심으로 $\text{eps} \in \{3.6, 3.8, 4.0, 4.2, 4.4, 4.6\}$, $\text{min_samples} \in \{4, 5, 6\}$ 에 대한 민감도 분석을 수행하였다. 모든 조합에서 군집 수는 1개로 일정하게 나타났으며 이상치 수만 9~14개 사이에서 변동하였다.

이는 밀도 기반 관점에서 161개국의 무역구조가 하나의 연속적인 큰 덩어리(군집)를 형성하고 있으며, 그 가장자리에 위치한 소수 국가만 저밀도 지역으로 분리됨을 의미한다. 이 발견은 3.2절에서 관찰한 낮은 실루엣 점수(0.158)와 일관된다. 본 분석에서는 DBSCAN을 별도의 군집화 도구가 아니라 순수한 이상치 탐지기로 활용하는 것이 적절하다고 판단하여, $\text{eps}=4.2$, $\text{min_samples}=5$ 를 최종 파라미터로 채택하였다.

4.4 탐지된 이상국 및 해석

최종 파라미터 기준으로 12개국이 이상치(noise, label=-1)로 식별되었다.



[그림 9] PCA 평면상의 DBSCAN 이상국 위치

국가	K-Means 소속 군집	이상치 사유
콩고민주공화국(COD)	자원수출 의존형	자원렌트/GDP 극단적, 수출HHI 0.48
레소토(LES)	섬유의류 특화형	무역수지/GDP 극단적 적자
통가(TON)	농식품 수출형	초소형 태평양 도서국, 극단적 무역적자
마카오(MAC)	섬유의류 특화형	서비스·카지노 허브 특수성
캄보디아(KHM)	섬유의류 특화형	무역개방도 극단적
라이베리아(LBR)	농식품 수출형	자원렌트/GDP 극단적
알바니아(ALB)	섬유의류 특화형	주변국과의 밀도 부족
안도라(AND)	제조업/가공무역형	초소형 경제, 특수 통계구조
보스니아(BIH)	제조업/가공무역형	주변국과의 밀도 부족
이스라엘(ISR)	제조업/가공무역형	무역개방도 낮음, 군집 경계
아일랜드(IRL)	제조업/가공무역형	조세회피 관련 무역구조 왜곡
팔레스타인(PSE)	제조업/가공무역형	특수 정치경제 상황

탐지된 이상국은 크게 세 유형으로 구분된다: (1) 극단적 자원 의존국(콩고민주공화국, 라이베리아), (2) 무역수지가 GDP 대비 극단적으로 큰 초소형 개방경제(레소토, 통가, 캄보디아), (3) 특수

경제구조(마카오의 서비스 허브, 아일랜드의 조세회피 구조). 나머지(알바니아, 안도라, 보스니아, 이스라엘)는 군집 경계 부근에 위치한 점이적 사례로, 다음 장의 RF/SVM 분석에서도 경계 국으로 재확인된다.

5. RF/SVM: 군집 분리 일관성 확인

5.1 분석 방법 및 한계

K-Means가 생성한 군집 레이블을 정답으로 간주하고, Random Forest와 SVM(RBF 커널)이 5-fold 교차검증을 통해 이 레이블을 얼마나 정확히 학습·재현할 수 있는지 평가하였다. 또한 두 분류기 중 하나라도 K-Means 레이블과 다르게 예측한 국가는 군집 경계에 위치한 경계 국가로 정의하였다.


방법론적 한계에 대한 주의

이 검증은 K-Means가 사용한 동일 18개 피쳐 공간에서 수행되었으므로, K-Means가 해당 공간에서 (준)불록 경계를 그었을 때 분류기가 이를 복원하는 것은 어느 정도 보장된 결과이다. 따라서 높은 정확도가 군집이 데이터에 실재하는 구조라는 강한 주장을 직접 뒷받침하지는 않는다. 본 분석에서는 이 결과를 군집 경계의 분리 가능성과 일관성 확인 및 경계국 식별의 용도로 해석한다. 독립적 구조 안정성 검증은 6장의 부트스트랩 ARI에서 별도 수행한다.

5.2 교차검증 정확도

모델	5-fold CV 정확도	비고
Random Forest (300 trees)	85.7%	class_weight='balanced' 적용
SVM (RBF kernel, C=1.0)	91.9%	class_weight='balanced' 적용


5.3 혼동행렬 분석



[그림 10] Random Forest(좌) 및 SVM(우) 혼동행렬

혼동행렬을 살펴보면, 자원수출 의존형과 귀금속/원자재 집중형은 두 모델 모두에서 높은 정확도로 분류되어 가장 안정적인 군집임을 확인할 수 있다. 반면 농식품 수출형과 제조업/가공무역형 사이, 그리고 섬유 의류 특화형 내부에서는 상대적으로 오분류가 더 많이 발생하여, 이들 군집 간 경계가 상대적으로 모호함을 시사한다.

5.4 변수 중요도



[그림 11] Random Forest 변수 중요도 (Top 12)

귀금속/보석 수출비중, 광물연료 수출비중, 섬유/의류 수출비중이 변수 중요도 1~3위를 차지한다. 다만 이들 변수는 군집 명명 기준 자체와 직결되므로, 이 결과를 독립적 발견이 아니라 변수

설계와 군집 구조 간 일관성 확인 정도로 해석하는 것이 적절하다.

5.5 경계 국가 식별

RF 또는 SVM 중 하나라도 K-Means 레이블과 다르게 예측한 국가는 총 29개국(전체의 18.0%)으로 식별되었다. 이 중 다수가 DBSCAN이 식별한 이상국과 중복되어, 서로 독립적인 두 가지 이상치 탐지 방법(밀도 기반 vs. 분류기 기반) 간 상호 검증이 성립함을 확인하였다.

6. 부트스트랩 ARI: 구조 안정성의 독립 검증


6.1 분석 배경 및 방법

5장의 RF/SVM 검증은 동일 feature 공간에서의 복원이라는 한계가 있다. 이를 보완하기 위해, 데이터 부분집합에서 군집 구조가 얼마나 안정적으로 재현되는지를 측정하는 독립적 검증을 수행하였다.

방법은 다음과 같다: (1) 전체 161개국 중 80%(약 129개국)를 무작위 비복원 추출하고, (2) 해당 서브샘플에서 K-Means($k=5$, $n_{init}=20$)를 새로 학습시키고, (3) 서브샘플에 해당하는 원래 군집 레이블과 새 군집 레이블 간의 Adjusted Rand Index(ARI)를 측정한다. 이를 100회 반복하여 ARI 분포를 얻는다.

ARI는 0~1 범위의 값을 가지며, 두 군집 배정이 완전히 일치하면 1, 무작위 배정이면 0에 가깝다. 일반적으로 $ARI > 0.9$ 는 매우 안정적, 0.7~0.9는 양호, 0.5~0.7은 보통, < 0.5 는 불안정으로 해석한다.

6.2 결과 및 해석



[그림 12] 부트스트랩 ARI 분포 (100회, 80% 서브샘플)


평균 ARI는 $0.697(\pm 0.117)$ 로 양호한 수준이다. 이는 80% 서브샘플에서도 군집 구조의 약 70%가 일관되게 재현됨을 보여준다. 다만, 최소 ARI는 약 0.4, 최대는 약 0.95로, 대부분의 서브샘플에서 군집 구조가 안정적이지만 특정 국가 조합에서는 불안정해질 수 있음을 알 수 있다.

위 결과는 K-Means의 5개 군집이 표본 구성에 크게 의존하지 않는 실질적 구조임을 독립적으로 지지하는 결과이다. 동시에 ARI가 0.9에 미치지 못하는 것은 실루엣 0.158, DBSCAN 군집 수 1개와 함께, 국가 무역구조가 뚜렷한 5개 군집보다는 연속적 스펙트럼을 해석 편의상 5개로 분할한 것에 가깝다는 일관된 해석을 뒷받침하는 수치이다.

7. 군집별 심층 분석

7.1 군집 안정성 종합 비교

DBSCAN 이상국 비율과 RF/SVM 경계국 비율을 함께 살펴보면, 군집별 안정성에 뚜렷한 차이가 나타난다.



[그림 13] 군집별 핵심 거시지표 분포 (제조업VA비중, 자원렌트비중, 수출HHI, 무역개방도)

군집	명칭	DBSCAN 이상국	RF/SVM 경계국	안정성	해석
C0	섬유의류 특화형	4개 (40%)	7개 (70%)	낮음	가장 불안정
C1	농식품 수출형	2개 (3%)	11개 (19%)	중간	내부 다양성 큼
C2	귀금속/원자재 집중형	0개 (0%)	2개 (11%)	높음	안정적 분리
C3	제조업/가공무역형	5개 (10%)	8개 (16%)	중간	경계국 다수
C4	자원수출 의존형	1개 (4%)	1개 (4%)	매우 높음	가장 안정적

자원수출 의존형(C4)은 DBSCAN 이상국 1개(4%), RF/SVM 경계국 1개(4%)로 5개 군집 중 가장 명확하게 분리되는 안정적인 유형이다. 이는 자원 의존도라는 변수가 국가 무역구조를 구분하는 데 있어 가장 강력한 차별화 요인임을 의미한다.

반면 섬유의류 특화형(C0)은 표본 수가 적고(10개국) 이상국·경계국 비율이 각각 40%, 70%에 달해 가장 불안정한 군집으로 나타났다. 이는 섬유의류 수출국들이 동시에 농식품 수출이나 광물자원 수출 등 다른 특성도 함께 보유한 경우가 많아, 단일 군집으로 묶기에는 내부 이질성이 클 가능성을 가진다고 해석하였다. 다만 C0은 표본이 10개국에 불과해 1~2개국의 이동만으로

도 비율이 크게 출렁일 수 있으므로, 위 수치를 군집의 본질적 이질성에 대한 확정적 근거로 단정하기보다는 추가 표본 확보 후 재검증이 필요한 잠정적 신호로 해석하는 것이 타당할 것이다. 이에 향후 k=6으로 확장하거나 별도의 소군집으로 분리하는 것을 검토할 필요가 있음을 제안한다.

7.2 특정 경계 국가 중심의 벤치마킹 갭(Gap) 분석

앞 절들이 군집 전체의 안정성을 다루었다면, 본 절에서는 개별 경계 국가 하나를 선정하여 해당 국가가 소속 군집의 중심(centroid)과 구체적으로 어떤 변수에서 얼마나 차이를 보이는지 탐색적으로 살펴본다. 이는 인과관계나 정책 효과를 추정하는 것이 아니라, 군집 중심까지의 Euclidean 거리를 변수별로 분해하여 '어느 지점에서 차이가 가장 크게 나는가'를 기술하는 거리분해 분석이다.

대상국 선정: 요르단(JOR)

5장에서 식별된 29개 경계국 중, C3(제조업/가공무역형)에 속한 8개국(스위스, 아일랜드, 지부티, 요르단, 미국, 팔레스타인, 에스와티니, 트리니다드토바고) 가운데 중동의 신흥 산업화 개도국인 요르단을 대상으로 선정하였다. 요르단은 RF/SVM 경계국으로 식별되었으며 (boundary=True), C3 군집 51개국 중 중심까지의 거리 기준 37위(주변부)에 위치한다. 참고로 같은 군집의 미국 역시 경계국으로 식별되었으나, 이는 본 분석의 목적인 제조업으로의 전환 경로 탐색과는 결이 다른 사례(이미 최상위 제조업 강국)이므로 본 절의 대상에서는 제외하였다.

C3 군집 중심과의 변수별 격차

요르단의 18개 변수값과 C3 군집 중심값(centroid)을 비교한 결과는 다음과 같다.

변수	요르단	C3 중심	Gap
무역개방도 (%)	72.5	89.2	-16.7
제조업 VA/GDP (%)	17.3	15.1	+2.2
수출 HHI	0.07	0.11	-0.03

기계/전자/운송 수출비중	7.1%	39.2%	-32.1%p
화학 수출비중	34.6%	14.0%	+20.6%p
섬유/의류 수출비중	16.2%	4.0%	+12.3%p
귀금속/보석 수출비중	9.9%	4.0%	+5.9%p

격차가 가장 큰 변수는 기계/전자/운송장비 수출비중으로, 요르단(7.1%)은 C3 평균(39.2%)에 크게 못 미친다. 반대로 화학(+20.6%p), 섬유/의류(+12.3%p), 귀금속/보석(+5.9%p) 비중은 군집 평균을 상회한다. 무역개방도 또한 군집 평균보다 16.7%p 낮아, 요르단의 무역구조는 C3에 속하면서도 화학·1차가공품 중심의 중간 단계에 머물러 있는 것으로 해석할 수 있다.

다만 이 갭(Gap) 수치는 거리 분해의 결과일 뿐이며, 특정 비중을 몇 %p 조정하면 군집 중심으로 이동한다는 인과적 처방으로 해석해서는 안 된다. 수출 구조의 전환은 수십 년에 걸친 산업 정책, 자본 축적, 기술 이전 등 복합적 요인에 의해 결정되며, 본 분석은 그러한 동태적 과정을 모델링하지 않는다. 본 절의 기여는 '현재 시점에서 어떤 변수가 군집 평균과 가장 크게 벌어져 있는가'를 정량적으로 드러내는 데 한정되며, 이는 후속 연구에서 시계열 데이터를 활용해 인과적으로 검증해야 할 가설을 제시하는 수준의 의미를 가진다.

7.3 군집별 GDP 성장률 비교

'어떤 경제 체질이 성장에 유리한가'를 검증하기 위해 군집별 GDP 성장률을 비교하였다. 평균은 극단값에 취약하므로 중앙값을 기준으로 해석하였다.

군집	평균(%)	중앙값(%)	비고
섬유의류 특화형	9.93	3.78	마카오(75.3%, 기저효과)가 평균을 왜곡
농식품 수출형	3.92	3.70	
귀금속/원자재 집중형	4.33	3.85	
제조업/가공무역형	1.80	1.82	5개 군집 중 유일하게 낮음
자원수출 의존형	3.77	3.46	

평균 기준으로는 섬유의류 특화형(9.9%)이 가장 높아 보이지만, 이는 마카오(75.3%, 코로나 회

북 기저효과) 단일 국가에 의한 왜곡이다. 마카오를 포함한 중앙값으로 비교하면 제조업/가공무역형(1.82%)만 유의하게 낮고, 나머지 4개 군집은 3.5~3.9%로 비슷한 수준이다. 이는 산업화·가공무역 구조가 이미 성숙한 경제(중국, 독일, 일본 등 선진 제조국 다수 포함)일수록 성장 여력이 상대적으로 낮은, 전형적인 성장 둔화 패턴으로 해석할 수 있다.

7.4 변수 중요도 가설 대조: 거시구조 변수 vs 수출 카테고리 변수

당초 거시구조 변수의 중요도 순서를 $Mfg_VA_GDP > Res_Rent_GDP > Trade_Balance_GDP > HHI_export$ 로 예상하였으나, 실제 RF 변수 중요도는 이와 크게 달랐다.

변수	예상 순위	실제 순위(18개 중)	중요도
Mfg_VA_GDP	1위	15위	0.026
Res_Rent_GDP	2위	4위	0.084
Trade_Balance_GDP	3위	11위	0.029
HHI_export	4위	7위	0.058

가설과 정반대로 거시구조 변수는 대부분 중요도 하위권(11~15위)에 머물렀고, 수출 카테고리 비중 변수(귀금속/보석, 광물연료, 섬유/의류)가 1~3위를 차지하였다. 이는 18개 변수 중 13개가 수출 카테고리 변수이고, K-Means 군집 자체가 수출 구조 차이로 가장 뚜렷하게 갈리기 때문으로, 거시지표보다 '무엇을 수출하는가'가 군집 구분에 훨씬 직접적인 정보를 제공함을 보여준다. 다만 Res_Rent_GDP는 18개 중 4위로 거시구조 변수 중 유일하게 상위권에 위치하여, 자원 의존도만큼은 가설처럼 중요한 변수로 확인되었다.

7.5 군집 간 보완적 무역구조 분석

상호 보완적 무역 파트너 발굴을 검증하기 위해 표준 무역보완지수(TCI, Trade Complementarity Index)를 적용하였다. $TCI(j,k) = 100 \times (1 - 0.5 \times |수출비중j - 수입비중k|)$ 로,

0~100 범위에서 높을수록 j의 수출구조가 k의 수입구조와 잘 맞는다.

군집 평균으로 우선 계산을 시도하였으나, 군집간 수입 프로파일의 표준편차(최대 0.066)가 수출 프로파일 표준편차(최대 0.263)보다 4배 이상 작아 수입구조 자체가 군집과 무관하게 동질적임을 확인하였다. 이 상태로 군집평균 기반 보완지수를 산출하면 실질적 보완관계가 아니라 '어느 군집의 수출이 세계 평균 수입바스켓과 비슷한가'만을 측정하게 되므로, 국가 단위로 TCI를 계산한 뒤 군집간 평균을 취하는 방식으로 재설계하였다.

수출 군집	최고 보완 수입 군집	평균 TCI
섬유의류 특화형	농식품 수출형	46.7
농식품 수출형	섬유의류 특화형	54.8
귀금속/원자재 집중형	섬유의류 특화형	39.4
제조업/가공무역형	자원수출 의존형	65.7
자원수출 의존형	귀금속/원자재 집중형	41.0

가장 두드러진 보완관계는 제조업/가공무역형의 수출이 자원수출 의존형의 수입과 맞는 관계(평균 TCI=65.7)이다. 그러나 이는 비대칭적이다. 반대로 자원수출 의존형의 수출이 제조업/가공무역형의 수입과 맞는 TCI는 34.9에 불과하다. 즉 제조업 국가의 다변화된 수출(기계·화학 등)은 자원수출국이 필요로 하는 수입품과 잘 맞지만, 자원수출국의 좁은 수출 포트폴리오(연료·광물 중심)는 제조업국이 수입하는 다양한 품목과는 상대적으로 덜 맞는다. 이는 자원-제조업 양진영 간 무역관계가 일방적 보완 구조에 가깝다는 것을 시사하며, 실제 사우디·UAE 등 자원수출국이 독일·한국 등 제조업국으로부터 기계·전자제품을 대량 수입하는 현실과 부합한다.

다만 개별 국가쌍 단위로 보면 네덜란드(로테르담 환적항)처럼 중계무역 비중이 큰 국가가 다수 국가와 비정상적으로 높은 TCI(90 이상)를 보이는데, 이는 실제 양자 무역관계가 아니라 환적·재수출 통계가 반영된 결과일 수 있어 해석에 주의가 필요하다.

8. 결론 및 시사점

8.1 주요 결론

(1) World Bank API per_page 보정 및 미발행 지표 범위 탐색으로 분석 대상을 기존 150개국에서 161개국으로 확대하였다. 미국·영국·베트남·UAE 등 주요 교역국이 포함되어 보다 완전한 분석을 수행하였으며, 이들의 군집 배정이 경제적 직관과 부합함을 확인하였다.

(2) 96개 HS 챗터 기반 원본 수출비중 변수는 PCA로도 뚜렷한 저차원 구조를 보이지 않아(20개 주성분으로 55%), 13개 경제 카테고리 통합한 변수 설계가 해석 가능성과 군집 품질을 모두 높이는 데 효과적이었다.

(3) K-Means($k=5$)는 자원수출 의존형, 제조업/가공무역형, 농식품 수출형, 섬유의류 특화형, 귀금속/원자재 집중형이라는 경제학적으로 해석 가능한 5개 무역구조 유형을 도출하였다.

(4) DBSCAN은 모든 파라미터 조합에서 군집 수 1개로 나타나, 밀도 기반 관점에서 국가 무역구조는 하나의 연속적 스펙트럼을 형성하며, K-Means의 5개 군집은 이 스펙트럼을 해석 가능한 단위로 분할한 것임을 확인하였다. 12개 이상국은 극단적 자원의존국, 초소형 개방경제, 특수 경제구조로 분류된다.

(5) 부트스트랩 ARI(평균 0.697 ± 0.117)는 RF/SVM의 동일 피쳐 공간 내 복원이라는 한계를 보완하여, 데이터 부분집합에서의 군집 구조 안정성을 독립적으로 검증하였다. 이 값은 5개 군집이 표본 구성에 크게 의존하지 않는 실질적 구조임을 양호한 수준으로 지지한다.

(6) 당초 가설과 달리 제조업 부가가치 비중과 자원렌트 비중 간 상관관계는 약하게 나타나(-0.12), 제조업과 자원수출을 동시에 영위하는 복합형 경제가 존재함을 확인하였다.

(7) 자원수출 의존형은 가장 안정적인 군집(DBSCAN 이상국 4%, 경계국 4%)이며, 섬유의류 특화형은 가장 불안정한 군집(이상국 40%, 경계국 70%)으로 나타났다. DBSCAN 이상국과

RF/SVM 경계국은 동일한 18개 피처 공간의 거리·밀도에 기반하므로 완전히 독립적인 검증은 아니며 실제로 8개국 이 중복 식별되었으나(4장, 5장 참조), 서로 다른 알고리즘적 관점(밀도 기반 vs. 분류기 기반)에서 동일한 패턴이 수렴한다는 점과, 이와는 방법론적으로 독립적인 부트스트랩 ARI(6장)에서도 같은 방향의 결과가 확인된다는 점에서 군집별 안정성 차이는 신뢰할 수 있는 결과로 판단된다.

8.2 분석의 한계

(1) 단일 연도(2023년) 데이터를 기반으로 한 단면적분석으로, 무역구조의 시계열적 변화나 동태적 전환(예: 산업고도화 경로)은 포착하지 못한다.

(2) HS 챗터를 13개로 통합하는 과정에서 일부 인위적 분류 기준이 개입되었으며, 분류 기준을 달리할 경우 군집 결과가 달라질 수 있다.

(3) $k=5$ 라는 군집 수는 여러 지표를 종합한 분석자의 판단에 의해 결정된 것으로, 절대적으로 유일한 최적값은 아니다.

(4) Res_Rent_GDP는 2023년 미발행으로 최신 가용연도(2021~2022) 값을 사용하여 다른 지표와 시점 불일치가 존재한다.

(5) 결측치 중앙값 대체(Mfg_VA_GDP 3개국, Trade_Balance_GDP 21개국)가 군집 배정에 미치는 영향을 완전히 배제할 수 없다.

8.3 후속 연구 제안

(1) 시계열 분석: 2010~2023년 연도별 데이터를 활용한 패널 Clustering으로, 국가의 무역구조 유형 전환 경로(예: 자원수출 → 제조업 전환)를 추적할 수 있다.

(2) 서비스 무역 포함: 현재 분석은 재화 무역에 한정되어 있어, 서비스 무역 데이터를 추가하면

아일랜드·마카오 등 서비스 허브 국가의 분류가 개선될 수 있다.

(3) Consensus Clustering: 부트스트랩 ARI를 확장하여, 여러 서브샘플의 군집 결과를 통합하는 합의 consensus clustering으로 더 안정적인 군집 배정을 도출할 수 있다.

(4) 본 연구는 K-Means의 경직된 군집 경계를 보완하기 위해 Gaussian Mixture Model(GMM)을 통한 소프트 클러스터링을 시도하였다. 그러나 18개 변수에 대해 full covariance를 적용할 경우 추정해야 할 파라미터 수(855개)가 표본 수(161개)의 5배를 초과하여 심각한 과적합 위험이 확인되었으며, 파라미터를 축소한 covariance 구조에서는 실루엣 점수가 K-Means보다 낮게 나타났다(0.059~0.158). 또한 GMM이 제공할 것으로 기대했던 혼합 소속정보, 즉 한 국가가 복수 군집에 걸쳐 있다는 정보도 평균 정규화 엔트로피 0.022로 사실상 거의 모든 국가가 단일 군집에 100%에 가깝게 배정되어, 기대했던 만큼의 추가적 통찰을 제공하지 못하였다. 이에 본 연구는 현재 표본 규모(161개국)에서는 GMM 적용이 실익보다 과적합 위험이 크다고 판단하여 K-Means를 최종 방법론으로 유지하였다. 표본이 충분히 확보될 경우(예: 연도별 패널 데이터 활용 시 관측치 확대) GMM 재적용이 유의미할 수 있다.

9. 참고문헌

Ahn, S. (2014). *Trade complementarity index and its application to bilateral trade flows*.

UNCTAD Trade Analysis Branch.

UNCTAD. (2024). *Trade Complementarity Index methodology*. UNCTADstat.

World Bank. (2024). *World Development Indicators*.

<https://databank.worldbank.org/source/world-development-indicators>

UN Comtrade. (2024). *International Trade Statistics Database*. <https://comtrade.un.org>

Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

World Customs Organization. (2022). *Harmonized System Nomenclature 2022 Edition*. WCO.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53-65.

Hubert, L., & Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2(1), 193-218.